

第八届中国研究生人工智能创新大赛

Sentinel-Guardian

企业 AI Agent 上线前自主安全审计与自动加固智能体

团队名称：TITAN 参赛组别：研究生组

Sentinel-Guardian 是一款面向企业 AI Agent 上线前安全验收的自主审计与自动加固智能体，解决现有安全工具“攻击、防御、决策”三者割裂、缺乏可审计闭环的核心痛点。

系统以 Docker 镜像为唯一接入形态，无需运行容器即可完成五阶段离线画像（入口/工具/权限/数据流/框架识别），覆盖 N1-N8 全部 Agent 流水线攻击节点，采用 STRIDE + MITRE ATLAS 双框架标注风险路径。攻击引擎内化 AgentDojo、InjecAgent、AgentHarm 三个国际 Benchmark 的攻击手法，结合画像驱动的反思-升级阶梯自动发现漏洞；防御模块在失效节点精确生成局部 Guard，通过 baseline/guarded 配对复测量化防御收益；最终输出“允许上线 / 修复复测 / 禁止上线 / 人工审批”四态决策及带证据绑定的完整审计报告。

核心实测指标：无防御攻击成功率（ASR）98.1%，加固后降至 12.4%，误报率（FPR）0%，正常业务效用 100%；OpenManus 真实容器审计 15/15 成功；1,068 项工程测试全部通过。系统支持 macOS 与 Windows 双平台桌面部署，通用接入任意 Docker 镜像 Agent。

（正文共 278 字，符合 300 字以内要求）